

# Raport końcowy


## Tytuł podsumowujący dany obszar prac

TRL	Opis z wniosku	Materiały w dokumentacji
	Fragment z wniosku projektowego.	Nazwy plików lub folderów, które dokumentują prace wypisane po lewej, lub N/A jeżeli nie istnieje odpowiedni dokument

Komentarz dotyczący danego zakresu prac. Co zostało zrobione, dlaczego w taki sposób, itp. W większości przypadków dokumentacja pokazuje stan prac na koniec projektu z pominięciem pośrednich wyników.

Zatwierdziła

Prezes Zarządu  
Joanna Hausner

Prezes Zarządu  
  
Joanna Hausner

IoT System Sp. z o.o.  
ul. Zofii Nałkowskiej 5/2  
40-425 Katowice  
NIP 954-27-63-070, Regon 363890923  
KRS 0000606263

Opracował

Kierownik Projektu  
dr Maciej Kozarzewski



## 3a - Detektor

TRL	Opis z wniosku	Materiały w dokumentacji
III	Stworzenie architektury sztucznej sieci neuronowej dostosowanej do zagadnienia detekcji osób bez ograniczeń w dostępie do mocy obliczeniowej. Zostanie przeanalizowanych wiele architektur - przykładami mogą być sieci typu RCNN czy SSD oraz zostaną przeprowadzone prace nad własną architekturą. Zastosowane zostaną też techniki typu "transfer learning" w których korzystając z głębokich sieci wytrenowanych na bardzo dużych zestawach danych, trenuje się jedynie ostatnie warstwy.	IIIA.1_person_detector.png - schemat architektury sieci neuronowej do detekcji
III	Implementacja wybranych architektur sieci.	IIIA.2_folder training - kod programu do treningu ( <u>do wglądu jeżeli będzie taka potrzeba</u> )
III	Opracowanie jej sposobu uczenia lub uczenia częściowego detektora.	
III	Zbadanie własności sieci oraz optymalizacja zarówno sieci jak i procesu trenowania.	IIIA.3_person_detector_small.png - schemat architektury nieco mniejszej sieci do detekcji
III	Detektor będzie miał sprawność powyżej 70% mAP (mean Average Precision) na danych benchmarkowych np. VOC 2012.	Wykresy mAP dla poszczególnych sieci: IIIA.4.1_mAP_person.png IIIA.4.2_mAP_person_small.png IIIA.4.3_mAP_car.png

W ramach tej części etapu III stworzono architekturę oraz wytrenowano sieć neuronową do detekcji. Jej architektura ewoluowała w trakcie trwania projektu, od podobnej do detektora YOLO (<https://pjreddie.com/darknet/yolo/>), przez podobną do połączenia detektorów YOLO i SSD (<https://arxiv.org/abs/1512.02325>), aż po finalną wersję, którą można podsumować jako połączenie architektury ResNet (<https://arxiv.org/abs/1512.03385>) z detektorem SSD. Zmiany wynikają po części z prac nad poprawieniem skuteczności, ale też z zwiększaniem szybkości i ułatwieniem późniejszej implementacji w warunkach ograniczonej mocy obliczeniowej.

W pierwszym podejściu do optymalizacji sieci została ona zmniejszona. Wypróbowaliśmy wiele wariantów by wybrać taki, który wiąże się z jak najmniejszym spadkiem skuteczności.

Sprawność detekcji (mAP - mean average precision) mierzyliśmy na obrazach pochodzących z archiwalnych nagrań z monitoringu udostępnionych przez firmę Netizens. Na tak przygotowanych danych wyniosła: mAP=73,7% (żółta linia, opisana jako "all") dla dużej wersji sieci i mAP=71,5% dla zmniejszonej, co spełnia założenia projektu. Należy mieć na uwadze, że skuteczność zależy od rozmiaru wykrywanych obiektów. Dla dużych obiektów (czyli takich jakie najczęściej się pojawiają na obrazach z kamer) skuteczność jest nieco większa. Dodatkowo stworzyliśmy sieć neuronową wykrywającą samochody, której skuteczność wynosi mAP=75,5%.

## 3b - Tracker

TRL	Opis z wniosku	Materiały w dokumentacji
III	Zbadanie różnych typów architektur pod kątem stosowalności do śledzenia obiektów. Punktem wyjścia będą są metody korelacyjne oparte na szybkiej transformacie Fouriera. Zostaną też przebadane sieci typu syjamskiego o architekturze konwolucyjnej, które są przykładem architektury od początku do końca uczącej się (end-to-end). Spodziewamy się, że prace nad tymi architekturami mogą być jedną z dróg realizacji pierwszej fazy adaptacji systemu do danej lokalizacji.	IIIB.1_siamese.png - schemat sieci neuronowej do porównywania wyglądu
III	Znalezienie sposobu optymalnej reprezentacji obiektu będzie ważnym elementem badań. Wspólną cechą krótko-czasowych algorytmów śledzących jest przetwarzanie pewnej reprezentacji obrazu śledzonego. Niezależnie od tego czy stosuje się ręcznie dobrane filtry czy samouczącą się sieć taka reprezentacja się pojawia. Niezbędne jest otrzymanie takiej reprezentacji by była ona niezależna wystarczająca swoista dla danego obiektu by nadawała się do powtórnej detekcji także pomiędzy różnymi kamerami.	
III	Opracowanie i implementacja wybranej architektury sieci	IIIB.2_folder training - kod programu do treningu ( <u>do wglądu jeżeli będzie taka potrzeba</u> )
III	Opracowanie sposobu jej trenowania.	
III	Zbadanie własności sieci oraz optymalizacja sieci jak i procesu trenowania	
III	W wyniku prac badawczych będzie można osiągnąć precyzję TRE (Temporal Robustness Evaluation) dla komponentu ST1 (tracker krótkoczasowy) na poziomie 70% dla danych OTB-50 czy OTB-100 przy znacznie zredukowanym poborze mocy obliczeniowej lub zastosowaniu akceleratora.	IIIB.3_Visual Tracker Benchmark.pdf

Nasze rozwiązanie do śledzenia obiektów jest wzorowane na tzw. sieci syjamskiej ([https://en.wikipedia.org/wiki/Siamese\\_neural\\_network](https://en.wikipedia.org/wiki/Siamese_neural_network)). Została ona połączona z detektorem MKnet w celu zwiększenia szybkości. Sieć MKnet oprócz wykrywania obiektów dla każdego z nich wylicza także pewien wektor cech. Wektory cech dla dwóch obiektów są ze sobą porównywane w celu wyliczenia prawdopodobieństwa, że te dwa obiekty to tak naprawdę ten sam obiekt. Takie prawdopodobieństwo jest następnie używane podczas śledzenia do lepszego łączenia trajektorii. Cechy wyliczane przez sieć nie zostały ręcznie dobrane, są to abstrakcyjne liczby, dobrane podczas procedury treningowej tak by umożliwiały jak najlepsze odróżnianie obiektów od siebie. Taki algorytm jest uniwersalny, może zostać zastosowany zarówno do śledzenia ludzi jak i samochodów bez żadnych modyfikacji (oprócz konieczności wytrenowania odpowiedniej sieci neuronowej).

Przetestowaliśmy takie rozwiązanie na zestawie danych OTB i otrzymaliśmy wynik 76% dla śledzenia ludzi, oraz 74% dla śledzenia samochodów.

## 3c - Śledzenie

TRL	Opis z wniosku	Materiały w dokumentacji
III	Integrację komponentów technologii ST1 i detektora i stworzenie algorytmu długoczasowego śledzenia (LT1)	IIC.1_folder training - kod programu do testowania komponentów śledzenia ( <u>do wglądu jeżeli będzie taka potrzeba</u> )
III	Testy i walidację systemu LT1 w warunkach laboratoryjnych na podstawie obrazów z różnego rodzaju lokalizacji.	IIC.2_folder filmy_OTB - filmy benchmarkowe OTB przetworzone przez sieć neuronową
III	Opracowanie algorytmu detekcji obiektu pojawiającego na wielu kamerach w oparciu o wyniki poprzednich badań nad reprezentacjami.	IIC.3_siamese.png - schemat sieci neuronowej do porównywania wyglądu
III	Analiza zapotrzebowania na moc obliczeniową prototypu laboratoryjnego modułu LT1	IIC.4_folder analiza_mocy_obliczeniowej - zbiór filmów przetworzonych przez algorytm, który oceniał zapotrzebowanie na moc obliczeniową
III	Zbadanie możliwości adaptacji modułu LT1 pod kątem użycia w warunkach ograniczonej mocy obliczeniowej.	

Zastosowanie trackera LT1 w warunkach ograniczonej mocy obliczeniowej wykorzystuje fakt, że kamery monitoringu są nieruchome. W związku z tym, dwie kolejne klatki z nagrania różnią się tylko w niewielkim stopniu. Nie ma więc potrzeby obliczania sieci neuronowej dla całego obrazu, a wystarczy jedynie nad tymi fragmentami, które się zmieniły. W celu zweryfikowania tego jak duża część obrazu się zmienia między dwoma klatkami, przygotowano kilka filmów testowych. Obraz z kamery został podzielony na kafelki i na przetworzonych filmach zostały podświetlone te kafelki, które w istotnym stopniu zmieniły się z klatki na klatkę. W lewym górnym rogu można zobaczyć wyliczoną średnią zmianę i chwilową. W tym konkretnym przypadku filmy z benchmarku OTB nie są dobrym przykładem ponieważ są krótkie, więc początkowy koszt obliczenia całej sieci neuronowej nie zdąży się zamortyzować w czasie. Jednak na nagraniach z rzeczywistych lokalizacji udostępnionych przez firmę Netizens, średnio zmienia się od 2% do 20% obrazu (nawet przy dużym zatłoczeniu). Oznacza to, że możemy się spodziewać od 5-krotnego (1/0.2) do 50-krotnego (1/0.02) przyspieszenia inferencji sieci neuronowych.

## 3d - Śledzenie w warunkach ograniczonej mocy obliczeniowej

TRL	Opis z wniosku	Materiały w dokumentacji
III	Zbadanie możliwości zastosowania zoptymalizowanej sztucznej sieci neuronowej w warunkach ograniczonej mocy obliczeniowej.	IIID.1_folder analiza_mocy_obliczeniowej - zbiór filmów przetworzonych przez algorytm, który oceniał zapotrzebowanie na moc obliczeniową
III	Stworzenie algorytmu hybrydowego, łączącego sieć neuronową o dużych wymaganiach obliczeniowych - zarówno detektor jak i tracker - z szybkim klasycznym algorytmem działającym w przypadku dobrego obrazu łatwo separowanego od tła.	N/A
III	Zbadanie stosowalności architektury klient-serwer w celu odciążenia lokalnych zasobów obliczeniowych, zarówno w fazie treningowej jak i produkcyjnej.	N/A
III	Zbadanie możliwości zastosowania współczesnych akceleratorów VPU np. Intel Movidius jako metody uzupełnienia mocy obliczeniowej.	IIID.2_raport z testów urządzenia Intel Movidius movidius.pdf
III	Zostanie stworzony system analizy obrazu na serwerach o dużej mocy obliczeniowej, na podstawie którego będzie konfigurowany lub trenowany system działający w warunkach ograniczonej mocy obliczeniowej. Jest to kluczowy element w wyniku którego powstanie "faza" adaptacji systemu do danego układu kamer. Faza ta będzie wykonana na systemach z dużą mocą obliczeniową i na jej podstawie zostanie stworzony algorytm śledzenia w oparciu o ograniczone zasoby obliczeniowe.	N/A
III	Zbadane zostaną warunki w jakich można wykonać trenowanie zoptymalizowanej sieci stosując system (LT1), w tym możliwość nadzorowanego przez człowieka tworzenia danych treningowych na podstawie posegmentowanych sekwencji wideo. Rozwiązaniem optymalnym jest takie które eliminuje udział człowieka w fazie adaptacji. Jednak na podstawie dotychczasowych doświadczeń nie można wykluczyć całkowicie jego udziału. W takim przypadku nacisk będzie położony na opracowanie procedur umożliwiających maksymalizację nadzoru nad automatycznym systemem. Przykładem może być tworzenie zbioru treningowego przez człowieka z wykorzystaniem segmentatora obrazu opartego na sieciach konwolucyjnych wytrenowanego na innym, szerszym zestawie danych. Ręcznie wykonano by zweryfikowane wyników i ich uzupełnienie w przypadku błędów. Po uzyskaniu niewielkiego zbioru prawidłowo posegmentowanych danych można dotrenować kilka ostatnich warstw konwolucyjnych i można powtórzyć procedurę aż sieć konwolucyjna będzie dobrze rozpoznawała obrazy z danej lokalizacji.	IIID.3_folder dataset_tool - narzędzie do ręcznego oznaczania zdjęć treningowych

Wydajność przetwarzania na zastosowanym komputerze z procesorem CPU Intel i7-3770 to około 100 klatek na sekundę (fps). Wydajność zależy od chwilowego natężenia ruchu, stąd przybliżona wartość 100fps jest średnią z całego nagrania użytego do testów.

Współczesnych akceleratorów VPU np. Intel Movidius mogą zostać użyte jako uzupełnienie mocy obliczeniowej. Przeprowadzone przez zespół testy sugerują wydajność na poziomie 30fps dla sieci MKnet. Wydajność ta jest zbyt mała by w tym momencie stanowiły one poważną alternatywę. Jest jednak na tyle duża, że należy dalej obserwować rynek akceleratorów VPU, bo z pewnością w przyszłości pojawią się nowe, szybsze warianty tego typu urządzeń.

Zastosowanie architektury klient-serwer w celu odciążenia lokalnych zasobów obliczeniowych wydaje się być dobrą alternatywą dla przetwarzania obrazu na miejscu. Jednak wykonana przez nas analiza techniczna i biznesowa wykazała, że klienci, którzy teoretycznie najbardziej skorzystaliby na tym rozwiązaniu (w powodu niskiej

wydajności komputerów na miejscu) jednocześnie mają stosunkowo niską przepustowość łącza internetowego. Transmisja filmów na zewnętrzny serwer wiązałaby się z nieakceptowalnym dla nich obciążeniem łącza internetowego. W związku z tym nie będziemy kontynuować prac w tym kierunku.

Na potrzeby ręcznego tworzenia danych treningowych został przygotowany specjalny edytor, który umożliwia obrysowywanie ludzi prostokątami. Wprawdzie zrezygnowaliśmy z fazy adaptacyjnej podczas instalowania systemu w nowej lokalizacji, edytor ten i tak znajdzie zastosowanie w przyszłości do zbierania większej ilości danych.

## 4 - Testowanie w warunkach laboratoryjnych

TRL	Opis z wniosku	Materiały w dokumentacji
IV	Celem tego etapu jest wykonanie ogólnego odwzorowania docelowego systemu w warunkach laboratoryjnych i jego przetestowanie. Do weryfikacji systemu śledzenia na podstawie analizy obrazu zostanie stworzony laboratoryjny system pomiarowy oparty na technologii radiowych smart-tag. Takie podejście umożliwi systematyczną weryfikację wyników działania modułu LT1 w przypadku zarówno ograniczonych zasobów jak i w wersji bez ograniczeń. Instalacja takiego systemu wraz z kamerami wideo umożliwi zarówno weryfikację wyników działania systemów śledzenia jak i dostarczyć danych do tworzenia modułu analizy statystycznej ruchu. Elementami takiej weryfikacji będą algorytmy transformujące trajektorię na obrazie do trajektorii w przestrzeni rzeczywistej monitorowanego obiektu. System bezpośredniego pomiaru położenia zostanie też wykorzystany do kalibracji systemów wideo i badań związanych z korektą obrazu związaną z różnicami kątów i odległości w kamerach z obiektami szerokokątnymi.	IV.1_folder uwb - zbiór zdjęć i filmów obrazujących działanie systemu
IV	System śledzenia zostanie przetestowany w oparciu o dane pochodzące z laboratoryjnej instalacji pomiarowej zawierającej smart-tag.	
IV	Stworzony zostanie moduł analizy statystycznej ruchu działający na danych dostarczanych przez zarówno długoczasowy system śledzący LT1 jak i system działający w warunkach ograniczonej mocy obliczeniowej oraz w fazie eksperymentalnej także danych pochodzących ze smart tagów. System ten będzie zawierał podstawowe elementy, które są istotne dla potencjalnego odbiorcy: liczby przejść przez daną bramkę, histogram obecności osób w różnych miejscach i statystyki zawierające korelacje długoterminowe - np. liczba osób które podeszły do punktu B a wcześniej byli w punkcie A.	
IV	Przeprowadzone zostaną wstępne prace mające na celu integrację systemu trackera długoczasowego LT1 z modułem analiz statystycznych w warunkach laboratoryjnych. System zostanie przetestowany i ewaluowany zarówno pod kątem technicznym jak i pod kątem potencjalnych zastosowań w praktyce.	

Na tym etapie głównymi celami prac było podniesienie gotowości technologicznej systemu śledzenia, w tym rozpoczęcie prób laboratoryjnych, połączenie komponentów w całość. Z drugiej strony prace obejmowały również inżynierię oprogramowania w celu zapewnienia kompatybilności na poziomie zarówno danych jak i architektury całego systemu.

W wyniku prac oba cele zostały wykonane. W instalacji laboratoryjnej zostały połączone dane pochodzące z rejestracji trajektorii metodą radiową oraz dane pochodzące z śledzenia obrazu wideo. Zgodność tych trajektorii była bardzo duża i umożliwiała policzenie interesujących z punktu widzenia zastosowań parametrów, takich jak np. liczba osób wchodzących do danego obszaru.

Ponadto uzyskano bardzo obiecujące wstępne wyniki optymalizacji ewaluatora sieci, który w warunkach rzeczywistych będzie działał w ograniczonej dostępności do mocy obliczeniowej.

Zweryfikowano działanie komponentów tracker i detektor jak i tracker LT1 w warunkach operacyjnych wykorzystując archiwalne nagrania z kamer z lokalizacji, w których system miałby działać. Sprawdzeniu podlegała skuteczność liczenia liczby osób przechodzących przez dane miejsce i otrzymano wynik na poziomie 75% skuteczności dla systemu bez ograniczeń mocy obliczeniowej i około 72% z mocą obliczeniową ograniczoną do pojedynczego rdzenia CPU (bez jakiegokolwiek fazy adaptacyjnej).

## 5 - Testowanie w symulowanych warunkach operacyjnych

TRL	Opis z wniosku	Materiały w dokumentacji
V	Testowanie i walidacja systemu w symulowanych warunkach operacyjnych. Przez warunki operacyjne rozumie się po pierwsze zarówno ograniczenie mocy obliczeniowej np. do pojedynczego CPU, a po drugie korzystania z obrazu wideo wykonanego kamerami pracującymi nieoptymalnie i w warunkach różnego rodzaju zakłóceń (np. zmienne w czasie oświetlenie).	V.1_folder ewaluacja
V	Wydajność symulowanych serwerów do przetwarzania i analityki obrazu opartej na systemie o ograniczonej mocy.	V.2_folder ml_runtime
V	Ustalenie zakresu i długości fazy treningowej dla systemu działającego w ograniczonej mocy obliczeniowej. To jest kluczowy element systemu, który zakłada, że dysponując konkretną lokalizacją możliwe jest zmniejszenie stopnia generalizacji układów analizujących za cenę ograniczenia ilości obliczeń.	N/A - nie robimy fazy adaptacyjnej
V	Działanie i efektywność użycia współczesnych akceleratorów VPU np. Intel Movidius jako metody uzupełnienia mocy obliczeniowej.	V.3_raport z testów urządzenia Intel Movidius movidius.pdf
V	Zbadanie praktycznych aspektów stosowalności architektury klient-serwer w celu odciążenia lokalnych zasobów obliczeniowych, zarówno w fazie treningowej jak i produkcyjnej. Zbadanie scenariuszy częściowego wspomagania systemu przez zdalny klaster obliczeniowy. W tym etapie zostanie stworzone środowisko zbliżone do rzeczywistego w którym będzie testowany długoczasowy algorytm śledzący. Środowisko to będzie zarówno zawierać ograniczoną moc obliczeniową jak kamery zbliżone parametrami do rzeczywistych kamer monitoringu.	N/A

Projekt zakładał wprowadzenie pewnego rodzaju fazy treningowej/adaptacyjnej dla systemu działającego w ograniczonej mocy obliczeniowej. Zakładano, że dysponując konkretną lokalizacją możliwe jest zmniejszenie stopnia generalizacji układów analizujących za cenę ograniczenia ilości obliczeń. W toku prac badawczych postanowiliśmy zrezygnować z tego pomysłu. Argumentujemy to następująco:

- wydajność systemu na CPU jest na tyle duża, że nie ma potrzeby dodatkowego zmniejszania ilości obliczeń
- skuteczność detekcji implementacji na CPU jest mniejsza lub równa (wynika to z przesłanek teoretycznych) skuteczności oryginalnej, ogólnej implementacji na GPU, ale podczas testów nie zauważyliśmy żadnego pogorszenia jakości detekcji.
- faza adaptacyjna wymagałaby stosunkowo dużo pracy człowieka przy wdrażaniu każdej nowej lokalizacji (konieczność zebrania i oznaczenia danych treningowych). Z punktu widzenia przyszłych zastosowań systemu bardzo pożądanym byłoby zredukowanie tej ilości pracy do zera (brak fazy adaptacyjnej) nawet gdyby odbyło się to kosztem pewnego spadku skuteczności.



## 6 - Testowanie w warunkach zbliżonych do rzeczywistych

TRL	Opis z wniosku	Materiały w dokumentacji
VI	Zostanie stworzony prototyp systemu, który będzie testowany w warunkach zbliżonych do rzeczywistych. Badania prototypu będą przeprowadzone w warunkach laboratoryjnych odwzorowujących z dużą wiernością warunki rzeczywiste lub w symulowanych warunkach operacyjnych. Prace przeprowadzone w tym etapie będą w dużym stopniu powtórzeniem prac z poprzedniego etapu. Zasadniczą różnicą jednak będzie, że spodziewamy się, że w poprzedzającym etapie zostanie zweryfikowane czy strategie zastosowania algorytmów wykorzystujących pojedyncze CPU jest efektywna i czy i w jakim stopniu zostaną zastosowane układy klasy VPU/NPU.	V.1_folder ewaluacja
VI	System LT1 działający na ograniczonej mocy obliczeniowej zostanie zintegrowany z prototypem systemu analizy statystycznej trajektorii ruchu.	<i>całość od początku była rozwijana w postaci zintegrowanej</i>
VI	Zweryfikowane zostaną własności otrzymywanych statystyk w zależności od wielkości ograniczeń sprzętowych. Na przykład zostanie zademonstrowane czy układ będzie w stanie i w jakich warunkach generować wyniki oparte na korelacjach długoczasowych.	<i>statystyki nie zależą od ograniczeń sprzętowych (tzn. wydajności sprzętu), zależą oczywiście od rozmieszczenia kamer, ale to nie jest przedmiotem badań w projekcie.</i>
VI	Zostanie przeprowadzona weryfikacja poprawności trajektorii z pomocą smart tagów na stanowisku eksperymentalnych. Wynikiem badań będzie zarówno system jak i analiza jego stosowalności w perspektywie sprzętu dostępnego danym momencie. Oznacza to, że będzie można określić dysponując przykładowym zapisem wideo zakres rodzajów analiz, które będą możliwe do wykonania zarówno na istniejącym sprzęcie w danej lokalizacji jak i po zainstalowaniu akceleratorów sprzętowych.	V.1_folder ewaluacja

Celem tego etapu było testowanie i walidacja systemu w symulowanych warunkach operacyjnych. Przez warunki operacyjne rozumie się po pierwsze zarówno ograniczenie mocy obliczeniowej np. do pojedynczego CPU, a po drugie korzystania z obrazu wideo wykonanego kamerami pracującymi nieoptymalnie i w warunkach różnego rodzaju zakłóceń (np. zmienne w czasie oświetlenie). W warunkach operacyjnych zostało zbadane:

- wydajność symulowanych serwerów do przetwarzania i analityki obrazu opartej na systemie o ograniczonej mocy jest taka sama jak w testach laboratoryjnych. Nie spodziewaliśmy się tutaj żadnych niespodzianek.
- w poprzednim etapie zdecydowaliśmy, że rezygnujemy z konieczności przeprowadzania dodatkowej fazy treningowej dla systemu działającego w ograniczonej mocy obliczeniowej.
- zastosowanie akceleratorów VPU może być obiecującym kierunkiem w przyszłości, ale w chwili obecnej ich wydajność nie jest wystarczająca.
- w poprzednim etapie zdecydowaliśmy, że z biznesowego punktu widzenia, stosowanie architektury klient-serwer nie jest możliwe.

Testy w symulowanych warunkach operacyjnych potwierdziły skuteczność i gotowość systemu otrzymaną we wcześniejszych testach w warunkach czysto laboratoryjnych.

## 7 - Testowanie w warunkach operacyjnych

TRL	Opis z wniosku	Materiały w dokumentacji
VII	Weryfikacja działania komponentów tracker i detektor jak i tracker LT1 w warunkach operacyjnych.	V.1_folder ewaluacja
VII	Weryfikacja systemu śledzenia w warunkach ograniczonej mocy obliczeniowej w warunkach operacyjnych.	
VII	Weryfikacja działania fazy adaptacji systemu śledzenia w warunkach ograniczonej mocy.	N/A - nie robimy fazy adaptacyjnej
VII	Stworzenie produkcyjnej wersji modułu analiz statystycznych trajektorii o oparciu o system śledzenia.	<i>całość od początku była rozwijana w postaci zintegrowanej</i>
VII	Weryfikacja skuteczności śledzenia na podstawie smart-tagów w warunkach operacyjnych (jeśli będzie możliwa instalacja tego systemu w warunkach operacyjnych).	N/A
VII	Stworzenie wizualizacji danych dla modułu analiz statystycznych trajektorii w oparciu o system śledzenia.	N/A

Ewaluacja trackera polegała na podłączeniu do systemu MovStat w celu przetestowania skuteczności wyliczania liczby osób przechodzących przez dane miejsce wykorzystując system do wrywkowego testowania skuteczności.

Instalacja systemu smart-tagów w warunkach operacyjnych nie była możliwa, jednak zespół przeprowadził wszystkie przygotowania i testy używając instalacji zamontowanej w biurze firmy. Ewentualna przyszła instalacja u klientów końcowych nie będzie stanowiła żadnego nowego problemu.

Stworzono dwa systemy pozyskiwania danych do oceny skuteczności, za pomocą smart-tagów oraz ręcznego oznaczania przejść przez dane miejsce. Z punktu widzenia pozostałych komponentów trackera, nie ma znaczenia z którego z tych dwóch źródeł pochodzą dane. Ponieważ we wcześniejszych badaniach i testach okazało się, że smart-tagi działają ze 100% skutecznością (tak jak ręczne przygotowanie danych), oznacza to, że podane wcześniej wyniki skuteczności nie zależą od sposobu wytworzenia danych testowych.

## 8 - Testowanie w warunkach operacyjnych

TRL	Opis z wniosku	Materiały w dokumentacji
VIII	Dostosowanie modułu analiz statystycznych trajektorii do możliwości systemu śledzenia. W zależności od jakości i ilości kamer jak i możliwości wykorzystania wszystkich danych przez moduł śledzenia będzie można otrzymać bardziej lub mniej rozbudowane statystyki.	<i>statystyki nie zależą od ograniczeń sprzętowych (tzn. wydajności sprzętu), ale oczywiście od rozmieszczenia kamer już tak</i>
VIII	Określona zostanie procedura adaptacji systemu do nowej lokalizacji obejmująca szkolenia osoby wdrażającej jak i sposób instalacji oprogramowania.	N/A - nie robimy fazy adaptacyjnej
VIII	Implementacja narzędzia dla adaptacji systemu w nowych lokalizacjach zawierająca funkcjonalności konfiguracji systemu dla badanych obszarów statystyk.	N/A - nie robimy fazy adaptacyjnej
VIII	Opracowane zostanie narzędzie do wrywkowej weryfikacji modułu śledzenia na bazie zdefiniowanych nagrań podczas działania systemu w warunkach rzeczywistych.	VIII.1_Tworzenie raportów zdarzeń.pdf VIII.2_Wybór parametrów dla testów.pdf
VIII	Opracowane zostanie architektura sprzętowa, oprogramowanie oraz narzędzia do automatyzacji procesu testowaniu podczas adaptacji systemu w nowych lokalizacjach. Rezultatem prac będzie prototypowy system V Analytics stanowiący rozwiązanie gotowe do wprowadzenia na rynek.	

W ramach prac objętych VIII. poziomem gotowości technologicznej została wykonana ocena systemów w celu potwierdzenia spełnienia założeń projektowych:

1. Dostosowanie modułu analiz statystycznych trajektorii do możliwości system śledzenia. W zależności od jakości i ilości kamer jak i możliwości wykorzystania wszystkich danych przez moduł śledzenia będzie można otrzymać bardziej lub mniej rozbudowane statystyki.

*Komentarz: Jeżeli interesujący dla klienta obszar jest dobrze widoczny na danej kamerze, to możemy liczyć każdą statystykę. Nie ma tutaj innych ograniczeń.*

2. Określona zostanie procedura adaptacji systemu do nowej lokalizacji obejmująca szkolenia osoby wdrażającej jak i sposób instalacji oprogramowania.

3. Implementacja narzędzia dla adaptacji systemu w nowych lokalizacjach zawierająca funkcjonalności konfiguracji systemu dla badanych obszarów statystyk.

*Komentarz: Zgodnie z wcześniejszą analizą, zrezygnowaliśmy z fazy adaptacyjnej.*

4. Opracowane zostało narzędzie do wrywkowej weryfikacji modułu śledzenia na bazie zdefiniowanych nagrań podczas działania systemu w warunkach rzeczywistych.

5. Opracowane zostanie architektura sprzętowa, oprogramowanie oraz narzędzia do automatyzacji procesu testowaniu podczas adaptacji systemu w nowych lokalizacjach.

*Komentarz: Jak w punktach 2 i 3. Wprowadzie system V analytics nie będzie wymagał fazy adaptacyjnej, jednak system do wrywkowej weryfikacji został przygotowany i zintegrowany z podobnym systemem dla programu MovStat.*

## 9 - Integracja z systemem MovStat

TRL	Opis z wniosku	Materiały w dokumentacji
IX	Opracowany zostanie interfejs komunikacyjny pomiędzy obecną wersją systemu a opracowany modułem śledzenia.	N/A
IX	Opracowany zostanie sposób zapisu danych oraz ich agregacji na potrzeby prezentacji danych dla klienta.	N/A
IX	Opracowany zostanie mechanizm kolekcji danych w celu późniejszej predykcji ruchu dla badanych obszarów oraz wykrywania niestandardowych zachowań.	N/A
IX	Dostosowanie opracowanego rozwiązania pod działanie na systemach operacyjnych Windows, Linux, MacOS. Rezultatem tego etapu prac będzie gotowy prototyp systemu V Analytics do detekcji i śledzenia obiektów, przetestowany w warunkach rzeczywistych.	N/A

Opracowany moduł śledzenia zostanie przetestowany w warunkach rzeczywistych poprzez jego podłączenie do funkcjonującego w firmie Netizens systemu MovStat na podstawie porozumienia zawartego z tą firmą.

1. Opracowany zostanie interfejs komunikacyjny pomiędzy obecną wersją systemu a opracowany modułem śledzenia.

*Komentarz: System V Analytics od początku był integrowany z MovStatem w sposób ciągły. Tak więc nie potrzeba specjalnego interfejsu komunikacyjnego (albo inaczej, został on wykonany w ramach prac we wszystkich wcześniejszych etapach).*

2. Opracowany zostanie sposób zapisu danych oraz ich agregacji na potrzeby prezentacji danych dla klienta.

*Komentarz: System V Analytics został podłączony do już istniejącego w MovStacie systemu zapisu i prezentacji danych. Dodano jedynie nowe funkcjonalności opisane w raportach z prac.*

3. Opracowany zostanie mechanizm kolekcji danych w celu późniejszej predykcji ruchu dla badanych obszarów oraz wykrywania niestandardowych zachowań.

*Komentarz: Jak wyżej.*

4. Dostosowanie opracowanego rozwiązania pod działanie na systemach operacyjnych Windows, Linux, MacOS.

*Komentarz: W wyniku analizy rozwiązań u potencjalnych klientów nie wykazano zastosowań systemów MacOS do obsługi systemów CCTV lub innych systemów wizyjnych, w związku z tym przygotowanie takiej implementacji jest bezcelowe.*